Numpy

2021

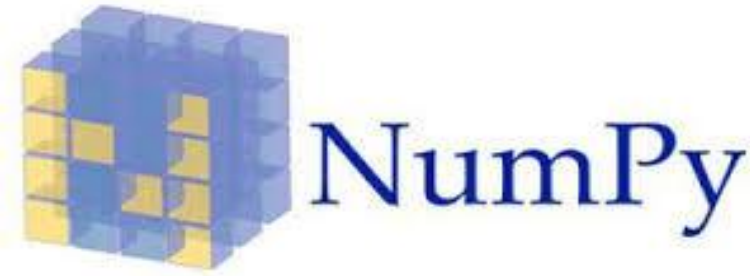

1. Numpy 란?

❖ 파이썬 과학 처리 패키지

- Numerical Python
- 파이썬의 고성능 과학 계산용 패키지
- Matrix와 Vector와 같은 Array 연산의 사실상의 표준

❖ 특징

- 일반 List에 비해 빠르고, 메모리를 효율적으로 사용
- 반복문 없이 데이터 배열에 대한 처리를 지원함
- 선형대수와 관련된 다양한 기능을 제공함
- C, C++ 등의 언어와 통합 가능

❖ References

- https://docs.scipy.org/doc/numpy/user/quickstart.html
- 데이터 사이언스 스쿨 (데이터 과학을 위한 파이썬 기초)
  https://datascienceschool.net/view-notebook/39569f0132044097a15943bd8f440ca5
- Numpy 강좌 https://www.youtube.com/playlist?list=PLBHVuYlKEkULZLnKLzRq1CnNBOBlBTkqp

2. ndarray(Numpy Dimensional Array)

❖ import

```
import numpy as np          # 표준화되어 있음
```

❖ Array 생성

```
test_array = np.array([1, 4, 5, 8], float)
print(test_array)
type(test_array[3])
print(test_array.dtype)   # Array 전체의 데이터 타입을 반환함
print(test_arry.shape)     # Array의 shape(차원 구성)을 반환함
```

- numpy는 np.array 함수를 활용하여 배열을 생성함 → ndarray
- numpy는 하나의 데이터 타입만 배열에 넣을 수 있음
- List와 가장 큰 차이점, Dynamic typing(예, [1, 2, "5", 4.2]) not supported
- C의 Array를 사용하여 배열을 생성함

3. Array shape

❖ Vector (1차원)

```
test_array = np.array([1, 4, 5, 8], float)
```

➔ shape은 (4,) : 1차원에 4개의 element가 있는 벡터

❖ Matrix (2차원)

```
matrix = [[1,2,5,8], [2,3,4,9], [4,5,6,7]]
np.array(matrix, int).shape
```

➔ shape은 (3, 4) : 행이 3개, 열이 4개인 매트릭스

❖ Tensor (3차원)

```
tensor = [[[1,2,5,8], [2,3,4,9], [4,5,6,7]],
          [[1,2,5,8], [2,3,4,9], [4,5,6,7]],
          [[1,2,5,8], [2,3,4,9], [4,5,6,7]],
          [[1,2,5,8], [2,3,4,9], [4,5,6,7]]]
np.array(tensor, int).shape
```

➔ shape은 (4, 3, 4) : 평면이 4개, 행이 3개, 열이 4개인 텐서

3. Array shape

❖ ndim & size

```
np.array(tensor, int).ndim    # 3, number of dimension
np.array(tensor, int).size    # 48
```

❖ dtype

```
np.array([[1, 2, 3], [4.5, '5', '6']], dtype=np.float32)
array([[1. , 2. , 3. ],
       [4.5, 5. , 6. ]], dtype=float32)
```

- Single element가 가지는 데이터 타입
- C의 데이터 타입과 호환
- nbytes – ndarray object의 메모리 크기를 바이트 단위로 반환함

❖ reshape

- Array의 shape을 변경함 (element의 개수는 동일)

3. Array shape

❖ reshape

```
test_matrix = [[1,2,3,4], [5,6,7,8]]
np.array(test_matrix).shape  ➔  (2, 4)
np.array(test_matrix).reshape(8, )  ➔  array([1,2,3,4,5,6,7,8])
np.array(test_matrix).reshape(8, ).shape  ➔  (8, )
```

- Array의 shape을 변경함 (element의 개수는 동일)
- Array의 size만 같다면 다차원으로 자유로이 변형가능

```
np.array(test_matrix).reshape(2, 4).shape  ➔  (2, 4)
np.array(test_matrix).reshape(-1, 2).shape  ➔  (4, 2)
                                  -1: size를 기반으로 row 개수 선정
np.array(test_matrix).reshape(2, 2, 2).shape  ➔  (2, 2, 2)
```

❖ flatten

```
test_matrix = [[[1,2,3,4], [5,6,7,8]], [[2,3,4,5], [6,7,8,9]]]
np.array(test_matrix).flatten()
➔ array([1,2,3,4,5,6,7,8,2,3,4,5,6,7,8,9])
```

- 다차원 array를 1차원 array로 변환

4. Indexing & slicing

❖ Indexing

```
a = np.array([[1,2,3], [4,5,6]], int)
print(a)
print(a[0,0])   # 2차원 배열 표기법 1
print(a[0][0])  # 2차원 배열 표기법 2
a[0, 0] = 1
```

- List와 달리 이차원 배열에서 [0, 0]과 같은 표기법을 제공함
- Matrix일 경우 앞은 행(row) 뒤는 열(column)을 의미함

❖ Slicing

```
a = np.array([[1,2,3,4,5], [6,7,8,9,10]], int)
a[:, 2:] # 전체 row의 2열 이상
a[1, 1:3]          # row 1의 1~2열
a[1:3]             # 1 row ~ 2 row 전체, column은 무시
a[:, ::2]          # step 가능
```

- List와 달리 행과 열 부분을 나눠서 slicing이 가능함
- Matrix의 부분 집합을 추출할 때 유용함

5. Creation function

❖ arange

```
np.arange(10)     # arange – List의 range와 같은 효과
➔ array([0, 1, 2, 3, 4, 5, 6, 7, 8, 9])
np.arange(0, 5, 0.5)       # floating point도 표시가능
➔ array([0. , 0.5, 1. , 1.5, 2. , 2.5, 3. , 3.5, 4. , 4.5])
np.arange(0, 5, 0.5).tolist()       # List로 만들 수 있음
np.arange(30).reshape(5, 6)         # size가 같으면 가능
```

❖ ones, zeros and empty

```
np.zeros(shape=(10,), dtype=np.int8)         # 원소가 10개인 벡터 생성
➔ array([0, 0, 0, 0, 0, 0, 0, 0, 0, 0], dtype=int8)
np.ones((2, 5))   # 2 x 5 – 값이 1인 matrix 생성
➔ array([1., 1., 1., 1., 1.],
        [1., 1., 1., 1., 1.]])
np.empty((3, 5))  # 메모리가 초기화되어 있지 않음
```

- empty – shape만 주어지고 비어있는 ndarray 생성

5. Creation function

❖ Something like

```
test_matrix = np.arange(30).reshape(5,6)
np.ones_like(test_matrix)
np.zeros_like(test_matrix)
```

- 기존 ndarray의 shape 크기 만큼 1, 0 또는 empty array를 반환

❖ identity (단위 행렬 생성)

```
np.identity(n=3, dtype=np.int8)                    # n → number of rows
➔ array([1, 0, 0],
        [0, 1, 0],
        [0, 0, 1]], dtype=int8)

np.identity(5)
➔ array([1., 0., 0., 0., 0.],
        [0., 1., 0., 0., 0.],
        [0., 0., 1., 0., 0.],
        [0., 0., 0., 1., 0.],
        [0., 0., 0., 0., 1.]])
```

5. Creation function

❖ eye (대각선이 1인 행렬)

```
np.eye(N=3, M=5, dtype=np.int8)
➔ array([[1, 0, 0, 0, 0],
         [0, 1, 0, 0, 0],
         [0, 0, 1, 0, 0]], dtype=int8)
np.eye(5)
➔ array([[1., 0., 0., 0., 0.],
         [0., 1., 0., 0., 0.],
         [0., 0., 1., 0., 0.],
         [0., 0., 0., 1., 0.],
         [0., 0., 0., 0., 1.]])
np.eye(3, 5, k=2) # k → start index
➔ array([[0., 0., 1., 0., 0.],
         [0., 0., 0., 1., 0.],
         [0., 0., 0., 0., 1.]])
```

❖ diag (대각 행렬의 값을 추출)

```
matrix = np.arange(9).reshape(3,3)
np.diag(matrix)
np.diag(matrix, k=1)       # k → start index
```

5. Creation function

❖ Random sampling(데이터 분포에 따른 sampling으로 array를 생성)

```
np.random.seed(seed=1000)                # 시드로 난수 생성 초기값 지정

np.random.uniform(0, 1, 10).reshape(2,5)     # 균등 분포
                  최소 최대 개수
np.random.normal(0, 1, 10).reshape(2,5)      # 정규 분포
                 평균 표준편차 개수

np.random.binomial(n, p, size)               # 이항 분포
np.random.poisson(lam. size)                 # 포아송 분포
np.random.standard_t(df, size)               # t-분포
np.random.f(dfnum, dfden, size)              # F-분포

import matplotlib.pyplot as plt
rand_norm = np.random.normal(0., 3., size=1000)       # 평균, 표준편차
count, bins, ignored = plt.hist(rand_norm, normed=False)

rand_pois = np.random.poisson(lam=20, size=1000)
unique, counts = np.unique(rand_pois, return_counts=True)
np.asarray((unique, counts)).T
plt.bar(unique, counts, width=0.5, color='red', align='center')
```

6. Operation function

❖ Sum

```
test_array = np.arange(1,11)
test_array.sum(dtype=np.float)  ➔  55.0
```

❖ Axis

- 모든 operation function을 실행할 때, 기준이 되는 dimension 축

```
test_array = np.arange(1,13).reshape(3,4)
➔ array([1, 2, 3, 4],
        [5, 6, 7, 8],
        [9,10,11,12]])

test_array.sum(axis=1)
➔ array([10, 26, 42])

test_array.sum(axis=0)
➔ array([15, 18, 21, 24])
```

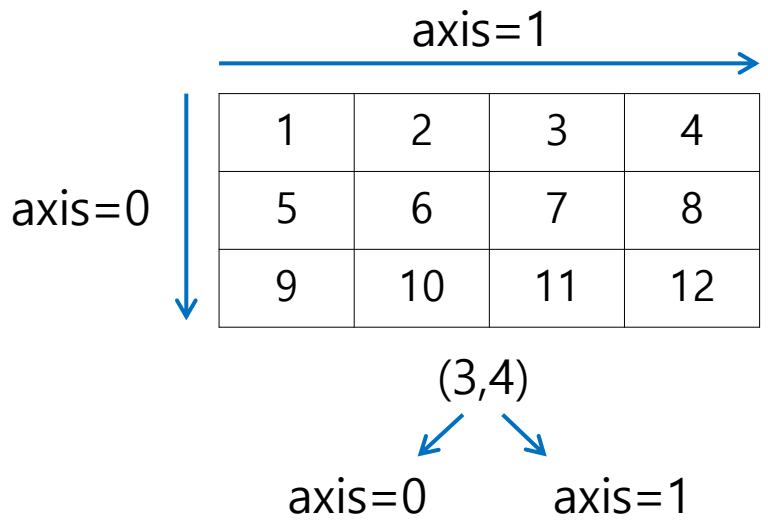

6. Operation function

❖ mean & std

```
test_array = np.arange(1,13).reshape(3,4)

test_array.mean() ➔ 6.5   # 평균(Mean)
test_array.mean(axis=0)
➔ array([5., 6., 7., 8.])

test_array.std()          # 표준 편차(Standard Deviation)
test_array.std(axis=0)
```

❖ Mathematical functions

```
지수 함수: exp, expml, exp2, log, log10, loglp, log2, power, sqrt
삼각 함수: sin, cos, tan, arcsin, arccos, arctan
Hyperbolic: sinh, cosh, tanh, arcsinh, arccosh, arctanh

np.exp(test_array)
np.sqrt(test_array)
```

6. Operation function

❖ Concatenate (Numpy array를 합치는 함수)

```
a = np.array([[1, 2], [3, 4]])
b = np.array([[5, 6]])
np.vstack((a,b))
➔ array([[1, 2],
         [3, 4],
         [5, 6]])
np.concatenate((a,b), axis=0)       # 위의 결과와 동일

a = np.array([[1], [2], [3]])
b = np.array([[2], [3], [4]])
np.hstack((a,b))
➔ array([[1, 2],
         [2, 3],
         [3, 4]])

a = np.array([[1, 2], [3, 4]])
b = np.array([[5, 6]])
np.concatenate((a, b.T), axis=1)            # T - Transpose
➔ array([[1, 2, 5],
         [3, 4, 6]])
```

7. Array operation

❖ Operations btw arrays (기본적인 사칙 연산 지원)

```
test_a = np.array([[1,2,3], [4,5,6]], float)
test_a + test_a
➔ array([2., 4., 6.],
        [8., 10., 12.]])
test_a - test_a
test_a * test_a            # Matrix element들 간의 곱, shape이 같을 때
                           # Element-wise product
```

❖ Dot product

```
test_a = np.arange(1,7).reshape(2,3)        # Matrix 곱셈
test_b = np.arange(7,13).reshape(3,2)       # (l,m) x (m,n) → (l,n)
test_a.dot(test_b)
➔ array([ 58,  64],
        [139, 154]])
```

❖ Transpose

```
test_a = np.arange(1,7).reshape(2,3)
test_a.transpose()
test_a.T
```

7. Array operation

❖ Broadcasting (Shape이 다른 배열간 연산 지원)

```
test_matrix = np.array([[1,2,3], [4,5,6]], float)
scalar = 3
test_matrix + scalar                # Matrix – Scalar 덧셈
➔ array([4., 5., 6.],
        [7., 8., 9.]])

test_matrix – scalar
test_matrix * scalar
test_matrix / scalar                # 나누기
test_matrix // scalar               # 몫
test_matrix ** 2                    # 제곱

# Matrix와 Vector간의 연산도 가능
test_matrix = np.arange(1,13).reshape(4,3)
test_vector = np.arange(10,40,10)
test_matrix + test_vector
➔ array([11, 22, 33],
        [14, 25, 36],
        [17, 28, 39],
        [20, 31, 42]])
```

8. Comparison

❖ All & Any

```
a = np.arange(10)
➔ array([0, 1, 2, 3, 4, 5, 6, 7, 8, 9])

np.any(a>5)  ➔  True      # any – 하나라도 조건에 만족하면 True
np.any(a<0)  ➔  False

np.all(a>5)  ➔  False     # all – 모두가 조건을 만족해야 True
np.all(a<10) ➔  True

a > 5
➔ array([False, False, False, False, False, False, True, True, True, True],
            dtype=bool)

test_a = np.array([1, 3, 0], float)
test_b = np.array([5, 2, 1], float)
test_a > test_b            # 배열의 크기가 동일할 때 원소간 비교 가능
➔ array([False, True, False], dtype=bool)

test_a == test_b
(test_a > test_b).any()
```

8. Comparison

❖ Logical operation

```
a = np.array([1, 3, 0], float)
b = np.logical_and(a>0, a<3)        # and 조건
➔ array([True, False, False], dtype=bool)

c = np.logical_not(b)
➔ array([False, True, True], dtype=bool)
np.logical_or(b,c)
➔ array([True, True, False], dtype=bool)

np.where(a>0, 3, 2)         # where(condition, True, False)
➔ array([3., 3., 2.],

a = np.arange(10, 20)
np.where(a>15)              # index 값 반환
➔ (array([6, 7, 8, 9], dtype=int64),)

a = np.array([1, np.NaN, np.Inf], float)
np.isnan(a)                 # is Not a Number?
np.isfinite(a)              # is finite number?
```

8. Comparison

❖ argmax & argmin (array내 최대값 또는 최소값의 index를 리턴)

```
a = np.array([1,2,4,5,8,78,23,3])
np.argmax(a), np.argmin(a)
➔ (5, 0)

a = np.array([[1,2,4,7],[9,88,6,45],[8,78,23,3]])
np.argmax(a, axis=1)
➔ array([3, 1, 1])
np.argmax(a, axis=0)
➔ array([1, 1, 2, 1])

np.argmin(a, axis=1)
➔ array([0, 2, 3])
np.argmin(a, axis=0)
➔ array([0, 0, 0, 2])
```

1	2	4	7
9	88	6	45
8	78	23	3

9. Boolean & fancy index

❖ Boolean index

```
test_array = np.array([1,4,0,2,3,8,9,7], float)
test_array > 3
➔ array([False, True, False, False, False, True, True, True],
          dtype=bool)

test_array[test_array > 3]   # 조건이 True인 index의 element만 추출
➔ array([4., 8., 9., 7.])

condition = test_array < 3
test_array[condition]
➔ array([1., 0., 2.])
```

9. Boolean & fancy index

❖ Fancy index

```
a = np.array([2, 4, 6, 8], float)
b = np.array([0, 0, 1, 3, 2, 1], int)        # 반드시 integer로 선언
a[b]              # b 배열의 값을 인덱스로 하여 a의 값들을 추출함
➔ array([2., 2., 4., 8., 6., 4.])  # bracket index

a.take(b)         # take 함수: bracket index와 같은 효과

a = np.array([[1,4], [9,16]], float)
b = np.array([0,0,1,1,1], int)
c = np.array([0,1,1,1,0], int)
a[b,c]            # b를 row index, c를 column index로 변환하여 표시
➔ array([1., 4., 16., 16., 9.])
```

10. 기술 통계

- 표본 평균 – np.mean()
- 표본 분산
  - np.var(x) # 모분산, 분모가 N
  - np.var(x, ddof=1) # 표본분산, 분모가 N-1,
- 표본 표준편차 – np.std()
- 최대값, 최소값 – np.max(), np.min(x)
- 중앙값 – np.median()
- 사분위수(quartile)
  - np.percentile(x, 0) # 최소값
  - np.percentile(x, 25) # 1사분위 수
  - np.percentile(x, 50) # 2사분위 수
  - np.percentile(x, 75) # 3사분위 수
  - np.percentile(x, 100) # 최대값

11. Numpy data I/O

❖ loadtxt & savetxt (Text type의 데이터를 읽고 저장하는 기능)

```
a = np.loadtxt(filename)   # 파일 호출
a[:10]

a_int = a.astype(int)
a_int[:3]

np.savetxt(filename, a_int, delimeter=',')   # csv 파일로 저장
```

❖ numpy object – npy

- Numpy object(pickle) 형태로 데이터를 저장하고 불러옴
- Binary 파일 형태

```
np.save('npy_test', arr=a_int)

npy_array = np.load(file='npy_test.npy')
```

12. 연습 문제

1. 넘파이를 사용하여 다음과 같은 행렬을 만드시오.

```
10 20 30 40
50 60 70 80
```

2. 다음 행렬과 같은 행렬이 있다.

```
m = np.array([[ 0,  1,  2,  3,  4],
              [ 5,  6,  7,  8,  9],
              [10, 11, 12, 13, 14]])
```

   1) 이 행렬에서 값 7 을 인덱싱한다.
   2) 이 행렬에서 값 14 을 인덱싱한다.
   3) 이 행렬에서 배열 [6, 7] 을 슬라이싱한다.
   4) 이 행렬에서 배열 [7, 12] 을 슬라이싱한다.
   5) 이 행렬에서 배열 [[3, 4], [8, 9]] 을 슬라이싱한다.

3. 2번의 행렬 m을 1차원 벡터 f 로 변환한 후 다음의 문제를 푸시오.
   1) 이 배열에서 3의 배수를 찾아라.
   2) 이 배열에서 4로 나누면 1이 남는 수를 찾아라.
   3) 이 배열에서 3으로 나누면 나누어지고 4로 나누면 1이 남는 수를 찾아라.

4. 값을 직접 입력하지 말고 우측의 행렬을 만드시오.

$$\begin{bmatrix} 2, & 1, & 0, & 0, & 0 \\ 3, & 2, & 1, & 0, & 0 \\ 0, & 3, & 2, & 1, & 0 \\ 0, & 0, & 3, & 2, & 1 \\ 0, & 0, & 0, & 3, & 2 \end{bmatrix}$$

12. 연습 문제

5. 0에서 10까지 랜덤 실수값으로 이루어진 5 x 6 형태의 데이터 행렬을 만들고 이 데이터에 대해 다음과 같은 값을 구하시오.
   1) 전체의 최댓값
   2) 각 행의 합
   3) 각 행의 최댓값
   4) 각 열의 평균
   5) 각 열의 최솟값

6. 다음 배열은 첫번째 행(row)에 학번, 두번째 행에 영어 성적, 세번째 행에 수학 성적을 적은 배열이다. 영어 성적을 기준으로 각 열(column)을 재정렬하시오.

```
array([[  1,   2,   3,   4],
       [ 46,  99, 100,  71],
       [ 81,  59,  90, 100]])
```

7. 주사위를 100번 던지는 가상 실험을 파이썬으로 작성하고,
   던져서 나오는 숫자의 평균을 구하시오.

8. 가격이 10,000원인 주식이 있다. 이 주식의 일간 수익률(%)은 기댓값이 0%이고 표준편차가 1%인 표준 정규 분포를 따른다고 하자. 250일 동안의 주가를 무작위로 생성하시오.